



SIGLO

21

INTELIGENCIA ARTIFICIAL - 2025

INF-404-11145

Trabajo Práctico 3

Módulo 3

Alumno: DIEGO DANIEL LUCHELLI

Titular experto: PABLO ALEJANDRO VIRGOLINI

Titular disciplinar: MARIA PAULA GONZALEZ

Fecha de entrega o fecha límite: 04/06/2025

Modalidad: Individual

Contenido

Desarrollo de la actividad	2
Contexto de la situación problemática.....	2
Consignas	2
Respuestas.....	2
Anexo	5
Bibliografía	5

Desarrollo de la actividad

Contexto de la situación problemática

Se encuentra en “Situación problemática” en canvas.

Consignas

1. Hacer un análisis de los modelos neuronales artificiales, poniendo el foco en las formas de aprendizaje y preparar un breve resumen de los mismos destacando sus aplicaciones.
2. Orientar el análisis anterior hacia la identificación de imágenes del tipo de las del problema abordado: modelos apropiados, ventajas y limitaciones.
3. Desarrollar e implementar un prototipo destinado a la identificación de imágenes a través del modelo de Hopfield en el contexto de un caso sencillo. Describir sus características, ventajas y limitaciones frente al problema tratado y presentar un ejemplo. También resumir las dificultades encontradas.
4. Analizar las coincidencias y diferencias entre el problema de fondo (línea de montaje) y las posibilidades que ofrecen el método aplicado y su prototipo. Justificar.

Respuestas

1. En el año 1943, Warren McCullock y Walter Pitts desarrollaron el primer modelo neuronal artificial, partiendo de la base de simular el funcionamiento del cerebro humano en una computadora. En este sentido, podemos definir al aprendizaje como la adquisición y modificación de conocimientos y habilidades mediante el entrenamiento, estudio, razonamiento y observación.

Al hablar de aprendizaje en las (RNA) Redes Neuronales Artificiales podemos destacar 2 principales:

- a. Aprendizaje Supervisado:
Este tipo de aprendizaje, consiste en entrenar la red con un conjunto de datos de entrada y sus correspondientes salidas-objetivo deseadas. Lo que se busca es que la red pueda aprender a identificar las salidas correctas de acuerdo con las entradas ingresadas.
 - i. Algunos de sus usos más frecuentes pueden ser:
 1. Reconocimiento de patrones
 2. Reconocimiento de voz
 3. Comparación de imágenes
 4. En algunos sistemas de control
- b. Aprendizaje No Supervisado:
En este caso, al contrario de aprendizaje supervisado, la red no recibe salidas-objetivo relacionadas a los patrones de entrada. La red debe descubrir por sí misma rasgos comunes, patrones o correlaciones entre los datos de entrada.

Durante este proceso los pesos y los umbrales de la red solamente como respuesta a sus propias entradas. Podemos hablar de dos tipos de redes de aprendizaje no supervisado:

- i. Redes de Kohonen (mapas autoorganizados o de aprendizaje competitivo)
- ii. Redes de Hopfield (Red autoasociativa)

Algunos de sus usos más frecuentes son:


1. Clustering (Agrupamiento de datos)
 2. Aplicaciones OCR (Reconocimiento óptico de Caracteres)
 3. Memoria asociativa (Recuperación de patrones a partir de entradas parciales o ruidosas)
2. En este punto podemos decir que el procesamiento de imágenes es una tarea para la cual las redes neuronales pueden aportar una gran potencia, esto se debe a su capacidad de aprender patrones directamente de sus datos de entrada como lo dijimos anteriormente, entonces, podríamos utilizar tanto modelos de aprendizaje supervisado como no supervisado y en cada uno de los casos nos encontraríamos con ventajas y limitaciones, aquí algunas de ellas:
- a. Aprendizaje supervisado
 - i. Ventajas:
 1. Capacidad de aprender relaciones entre las entradas y las salidas
 2. La retro propagación para ajustar el aprendizaje
 - ii. Limitaciones:
 1. No es eficiente cuando las imágenes son grandes
 2. No reaccionan bien a las variaciones en la ubicación de los objetos
 - b. Aprendizaje No Supervisado
 - i. Ventajas:
 1. No requiere de un etiquetado de datos
 2. Bien entrenadas pueden encontrar imágenes nunca vistas o que se encuentran ocultas
 - ii. Limitaciones:
 1. El modelo de Hopfield tiene limitaciones de los patrones que puede almacenar o un costo computacional muy elevado.
 2. Muchas veces resulta más eficiente trabajar con modelos supervisados.

3. A continuación, presento el prototipo propuesto y sus características:
Simulación de una red de Hopfield tomando una matriz de 12x12 (144 neuronas) que proporcionaría un círculo hueco de radio 4.

Se utilizó un código en Python generado con ayuda de IA, para poder realizar la simulación y mostrar el resultado obtenido. En este desarrollo se utilizan librerías como “numpy” para el cálculo de matrices, vectores y otras operaciones matemáticas y “matplotlib” para los gráficos, la mayoría está documentada en el código.

Se introduce la imagen original que genera un círculo hueco, se entrena la red y se agrega una segunda imagen con un patrón de ruido del 20%, este patrón tiene una distorsión aleatoria de modo que cada simulación resulte diferente a la anterior. Se recupera el patrón de la imagen y se calcula el centro del círculo.

Al ejecutar el código por ejemplo en PyCharm, se muestran las tres imágenes, la de origen, la imagen con ruido y el resultado con el centro marcado, luego al cerrar el cuadro se muestran las coordenadas de círculo en la consola.



Dificultades:

Entre las dificultades con la que me encontré al plantear este punto, quiero resaltar que noto cierta desconexión entre la solución presentada (simulación) y la situación problemática, e intentado utilizar la imagen suministrada, pero sin éxito. Por otro lado, me costó comprender que puntos debería desarrollar y con que profundidad.

4. Por último, voy a comentar sobre las Coincidencias, Diferencias y las posibilidades ofrecidas por el modelo aplicado:
 - a. Coincidencias: Para que existan coincidencias entre nuestra línea de montaje y el prototipo realizado, necesitamos que las imágenes de entrada estén en blanco y negro y no en tono de grises o color. Encontramos coincidencias al simplificar el caso a una matriz de 12x12 con un patrón binario.
 - b. Diferencias: Las diferencias están dadas por el tipo de imágenes y por la cantidad de patrones diferentes que pueden existir en una línea de montaje, dado que Hopfield posee una cantidad limitada de almacenamiento no se podría llegar a un resultado aceptable
 - c. Posibilidades: Si bien el prototipo permite simular una red de Hopfield, al ser este un modelo que utiliza patrones binarios puede ser útil con imágenes en blanco y negro, pero en imágenes como en la situación problemática, más cercanas a la vida real no resulta eficiente.

Como conclusión, puedo decir que para poder hacer un verdadero reconocimiento de las imágenes de nuestra línea de montaje, teniendo en cuenta la gran cantidad de patrones que pueden resultar de las diferentes posiciones en la que el block puede ocupar en el espacio, deberíamos utilizar otro tipo de redes como las Redes Neuronales Convolucionales (CNN).

Anexo

Los archivos de Python se encuentran en el siguiente repositorio de github:

https://github.com/lucca86/UE21_Inteligencia_Artificial_2025

Los archivos de este trabajo práctico son:

- LUCHELLI_Diego_Daniel_Inteligencia_Artificial_TP3.pdf
- Diego_Daniel_Lucchelli_TP3_Hopfield.py

Bibliografía

- UE Siglo 21 - **Canvas**
- **Platzi.** (s.f.). Entiende Naive-Bayes y sus fundamentos de implementación. Recuperado de <https://platzi.com/tutoriales/2081-ds-probabilidad/9010-entiende-naive-bayes-y-sus-fundamentos-de-implementacion/>
- **Red neuronal.** (s.f.). Definición de red neuronal. Recuperado de <https://sites.google.com/site/inteligenciascarol/red-neuronal?tmpl=%2Fsystem%2Fapp%2Ftemplates%2Fprint%2F&showPrintDialog=1#:~:text=Un%20ax%C3%B3n%20se%20define%20como,los%20axones%20de%20otras%20neuronas.>